

LLM 强化学习后训练：方法、演进与未来方向

完整调研报告

生成日期: 2026-06-23

数据基础: 280 篇系统性文献调研, 覆盖 2017-2026

生成 Agent: report_writer_agent

置信度约定: [确定] = 多篇论文交叉验证; [推断] = 基于趋势的合理判断; [争议] = 学术界存在明显分歧

摘要

LLM 强化学习后训练 (LLM RL Post-Training) 是大语言模型对齐人类偏好和获取复杂推理能力的核心技术栈。本报告基于 280 篇论文的系统性文献调研, 梳理了从 PPO-RLHF (2017-2022)、DPO 直接偏好优化 (2023)、DPO 变体爆发 (2024) 到 GRPO 推理训练革命和 Agentic RL (2025-2026) 的完整技术演进脉络。

核心发现包括: (1) GRPO 和 RLVR (可验证奖励强化学习) 是 2025-2026 年增速最快的方向, 31 篇 GRPO 论文全部发表于此期间; (2) DPO 方法族已趋于成熟, 新变体边际贡献递减; (3) Reward Hacking 是贯穿所有方法、至今无通用解决方案的核心挑战; (4) LLM-as-Judge 评估体系正经历可靠性危机, 单一排行榜排名不再可信; (5) Agentic RL 是 RLVR 范式的下一个主战场, 但面临信用分配和训练效率瓶颈。

报告详细呈现了方法分类体系 (训练范式、偏好建模、DPO 变体族、GRPO 机制)、实验室与团队格局 (OpenAI、Anthropic、DeepSeek、Stanford、Tsinghua 等)、评估体系现状与缺陷, 以及 8 个未解决问题和 4 个未来突破方向。

1. 引言与研究范围

1.1 方向定义

LLM 强化学习后训练是指在预训练完成之后，利用强化学习（RL）和偏好优化（Preference Optimization）方法，使大语言模型的输出符合人类价值观、偏好和安全要求的训练过程。其核心目标是在模型能力（capability）与对齐性（alignment）之间取得最优平衡。

核心方法谱系：

LLM 后训练方法

- └─ 监督微调（SFT）－ 行为克隆基础
- └─ 基于人类反馈的强化学习（RLHF）－ PPO + Reward Model
- └─ 直接偏好优化（DPO）及变体－ 绕过显式 RM
- └─ 组相对策略优化（GRPO）/ RLVR－ 可验证奖励驱动
- └─ AI 反馈强化学习（RLAIF）－ 用 AI 替代人工标注
- └─ Agentic RL－ Agent 场景的 RL 训练

1.2 研究范围

纳入标准 (参考 query_plan 第 8 节):

- LLM（参数量 > 1B）后训练阶段的 RL/偏好优化方法
- 基于人类偏好或 AI 反馈的对齐方法
- 在线 RL 和离线偏好优化方法
- Agent 场景的 RL 后训练
- Reward Modeling 和评估方法

排除范围：

- 预训练阶段的 RL 方法
- 纯视觉/多模态对齐（除非方法可迁移至 LLM）
- 传统 NLP 任务中的 RL（非生成式场景）
- 纯推理时对齐（prompt engineering、decoding strategies）

时间范围: 2017 年（PPO 提出）至 2026 年 6 月。重点关注 2023-2026 的高密度创新期。

数据来源: 280 篇论文通过 HuggingFace Papers API 检索 (索引自 arXiv), 覆盖 cs.CL、cs.LG、cs.AI 三个主要分类。检索策略详见 [research/query_plan.md](#)。

1.3 报告结构

2. 技术演进脉络 – 五阶段演进、关键转折点、时间线

3. 核心方法体系 – 训练范式、奖励建模、DPO 方法族、GRPO

4. 实验室与团队格局 – 工业界/学术界/开源社区、人才流动

5. 评估体系 – 评估框架、LLM-as-Judge 缺陷、信任危机

6. 未解决问题与挑战 – 方法/数据/评估/理论四个层面

7. 未来方向预判 – 四阶段预判、突破点分析

8. 结论

2. 技术演进脉络

2.1 奠基期 (2017-2020): PPO 算法基础与 RLHF 概念萌芽

核心问题: 策略梯度方法能否在保持训练稳定性的同时在复杂策略空间中优化? 人类偏好能否作为语言模型的奖励信号?

关键里程碑:

论文	年份	ARXIV ID	贡献	地位
PPO: Proximal Policy Optimization Algorithms (Schulman et al.)	2017	1707.06347	提出 Proximal Policy Optimization, 通过 clip 机制实现稳定在线策略优化, 成为后续所有 LLM RLHF 工作的优化器基石	★ 开创性
Deep Reinforcement Learning from Human Preferences (Christiano et al.)	2017	1706.03741	首次将人类偏好作为奖励信号训练 RL 智能体, RLHF 概念起源	★ 开创性

核心结论: PPO 算法是 LLM-RLHF 大厦的方法基石; Christiano et al. (2017) 是 RLHF 的思想起源。

2.2 RLHF 成型期 (2021-2022): 三阶段范式确立

核心问题: 如何系统化地将 RLHF 应用于大规模语言模型? 如何同时对齐 **helpfulness** 和 **harmlessness**?

关键里程碑:

论文	年份	ARXIV ID	贡献	地位
InstructGPT (Ouyang et al.)	2022	2203.02155	确立 SFT → RM → PPO 三阶段 RLHF 范式; 首次证明 RLHF 在 175B 模型上的有效性; KL 惩罚防止 language collapse	★ 开创性
Training a Helpful and Harmless Assistant (Bai et al.)	2022	2204.05862	引入 helpfulness 和 harmlessness 双目标 RLHF; 大规模偏好数据收集 (~161K 比较对)	★ 开创性
Constitutional AI (Bai et al.)	2022	2212.08073	提出 RLAIIF 范式: 用宪法原则指导 AI 自我 critique 和 revision, 用 AI 反馈替代人工反馈	★ 开创性

范式核心: InstructGPT 三阶段流水线——先用高质量示范数据做 SFT, 再训练 Reward Model 对输出打分, 最后用 PPO 在 RM 的奖励信号下优化策略。KL 约束 $\beta \cdot \text{KL}(\pi_{\theta} || \pi_{\text{ref}})$ 防止模型偏离太远导致语言退化。

核心结论: 2021-2022 年确立了 RLHF 的工业级范式。InstructGPT 的三阶段流水线成为后续所有方法的参考基线。Constitutional AI 开辟了 AI 反馈路线, 为 RLAIIF 奠定了基础。

2.3 偏好优化爆发期 (2023): DPO 革命

核心问题: 能否绕过显式 Reward Model, 直接在偏好数据上优化策略? 开源社区如何复现工业级 RLHF?

关键里程碑:

论文	年份	ARXIV ID	贡献	地位
DPO: Direct Preference Optimization (Rafailov et al.)	2023	2305.18290	发现 语言模型隐式包含奖励函数；通过 Bradley-Terry 偏好模型的闭式解，实现无需 RM 的直接偏好优化	★ 开创性
Llama 2 (Touvron et al.)	2023	2307.09288	首个开源工业级 RLHF 训练的 LLM；提供完整的 Ghost Attention、两阶段 RLHF、拒绝采样等实践细节	▲ 代表性
UltraFeedback (Cui et al.)	2023	2310.01377	~64K prompts 的高质量多维度偏好评分数据集；成为后续 DPO/RLHF 工作的标准训练数据	▲ 代表性
RLAIF (Lee et al.)	2023	2309.00267	系统化验证 AI 反馈可替代人工反馈进行 RLHF 训练	▲ 代表性
MT-Bench & Chatbot Arena (Zheng et al.)	2023	2306.05685	首次提出 LLM-as-Judge 评估范式和多模型竞技场 Elo 评分平台	★ 开创性
ToolLLM (Qin et al.)	2023	2307.16789	将 16000+ API 的工具使用能力纳入 LLM 训练，开启 Agentic RL 先河	★ 开创性

DPO 的理论突破：

DPO 的核心洞察：在 Bradley-Terry 偏好模型下，最优策略与 reward 函数存在闭式映射：

$$r(x,y) = \beta \cdot \log(\pi_{\theta}(y|x) / \pi_{\text{ref}}(y|x))$$

这意味着策略模型自身的输出 logits 隐式定义了一个 reward 函数。将偏好数据 (chosen vs rejected) 直接代入 BT 模型即得到 DPO 损失函数：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}[\log \sigma(\beta \cdot \log(\pi_{\theta}(y_w|x)/\pi_{\text{ref}}(y_w|x)) - \beta \cdot \log(\pi_{\theta}(y_l|x)/\pi_{\text{ref}}(y_l|x)))]$$

这使得对齐训练从"训练 RM → PPO 优化"两阶段简化为端到端的分类式优化。

核心结论: DPO 是 LLM 对齐领域自 *InstructGPT* 以来最大的方法突破。它降低了 *RLHF* 的实现门槛, 开启了偏好优化方法族的"淘金热" (后续产生 80 个变体)。但 DPO 也带来了新的问题: 离线数据分布偏移、*over-optimization* 依然存在 [2406.02900]、*Likelihood Displacement* 现象 [2410.08847]。

2.4 方法深化与多元化 (2024-2026)

2.4.1 2024: DPO 变体爆发年

核心趋势: DPO 向三个方向分化——简化架构 (去参考模型)、扩展数据需求 (非 pairwise)、在线化 (引入在线采样)。

关键里程碑:

论文	年份	ARXIV ID	核心创新
KTO (Ethayarajh et al.)	2024	2402.01306	基于前景理论, 仅需 $\checkmark/\times$ 标签 (无需 pairwise), 更贴合实际数据收集场景
ORPO (Hong et al.)	2024	2403.07691	合并 SFT 和偏好优化为单一阶段, 无参考模型, 内存/计算减半
SimPO (Meng et al.)	2024	2405.14734	长度归一化平均 log prob 作为隐式 reward, target margin γ , 匹配或超越 DPO
Online DPO (Qi et al.)	2024	2406.05534	Fast-Slow Chasing 机制实现在线 DPO, 突破离线数据分布限制
Iterative DPO (iLR-DPO) (Liu et al.)	2024	2406.11817	迭代 DPO + 长度正则化, 7B 模型接近 GPT-4 水平
Self-Play PO (SPPO) (Wu et al.)	2024	2405.00675	自博弈偏好优化, 无需 Bradley-Terry 假设, 博弈论视角

DPO 变体对比:

方法	REF MODEL	数据需求	核心公式创新
DPO	☒	pairwise	$\sigma(\beta \log \pi w / \pi_{\text{ref}} w - \beta \log \pi l / \pi_{\text{ref}} l)$
KTO	☒	单侧 $\checkmark/\times$	$\lambda w \cdot \sigma(z_{\text{ref}} - z) + \lambda l \cdot \sigma(z - z_{\text{ref}})$

方法	REF MODEL	数据需求	核心公式创新
IPO	✓	pairwise	回归目标替代分类目标
ORPO	✗	pairwise	SFT loss + odds ratio 偏好损失
SimPO	✗	pairwise	$\sigma(\beta \cdot \text{avg_log} \pi_w - \beta \cdot \text{avg_log} \pi_l - \gamma)$
ODPO	✓	pairwise	DPO + offset Δ (偏好强度差异)
β -DPO	✓	pairwise	动态 $\beta(x)$ 替代固定 β

[推断] DPO 变体的“淘金热”正在退潮。80 篇 DPO 论文中大部分发表于 2024 年，新变体的边际贡献递减。核心有持久价值的不超过 10 个。

2.4.2 2025: GRPO 革命与推理训练新范式

核心事件: DeepSeek-R1 [2501.12948] 发布, GRPO 成为推理 RL 的核心算法。

GRPO 算法的核心机制:

GRPO 与 PPO 的核心区别:

维度	PPO	GRPO
Advantage 估计	Value Network	组内相对归一化
需要 value Head?	✓	✗
Reward 需求	绝对奖励信号	相对排序即可
组比较	Batch 内隐式	显式同 prompt 多采样
计算开销	value func 训练	G 倍采样 (推理开销大)

GRPO 目标函数:

对每个 prompt x , 采样 G 个 responses $\{y_1, \dots, y_G\}$

$\hat{A}_i = (r_i - \text{mean}(r)) / \text{std}(r)$ ← 组相对 advantage

$\nabla J_{\text{GRPO}} = E[\hat{A}_i \cdot \nabla \log \pi_{\theta}(y_i | x)] - \beta \cdot \nabla \text{KL}(\pi_{\theta} || \pi_{\text{ref}})$

DeepSeek-R1 的关键发现:

- **DeepSeek-R1-Zero**: 纯 RL (无 SFT) + GRPO → reasoning 能力涌现, 包括自我验证、反思、替代方案探索
- **DeepSeek-R1**: 冷启动 SFT + RL, 效果更优, 避免纯 RL 初期的混乱输出

- 核心启示: 在有明确 **ground-truth** 可验证奖励（数学答案、代码执行结果）的场景下，RL 可以自主学习复杂的推理策略

GRPO 理论分析:

论文	核心发现
Demystifying GRPO (Zhou, 2026) 2603.01162	GRPO 策略梯度本质是 U-Statistic ，方差以 $O(1/G)$ 递减
On/Off-Policy GRPO (Mroueh, 2025) 2505.22257	GRPO 可在 on-policy 和 off-policy 模式下运作
GRPO is Off-Policy (Yao, 2025) 2509.24203	揭示 GRPO-like 的 REINFORCE 实际是 off-policy 算法

GRPO 的改进与变体:

变体	核心改进	论文
GRPO-VPS	将 process-level 验证信号集成进 GRPO	2604.20659
MO-GRPO	多目标 GRPO，缓解多目标场景 reward hacking	2509.22047
DaGRPO	解决 reasoning 中的梯度冲突	2512.06337
EBPO	Empirical Bayes 收缩稳定 advantage 估计	2602.05165
CPPO	Completion Pruning 加速训练	2503.22342
BiasGRPO	高方差 reward landscape 中的 bias 缓解	2606.04807
Latent-GRPO	将 GRPO 应用于连续隐空间推理	2604.27998
PAPO	Process-Aware Policy Optimization	2603.26535

2.4.3 2025-2026: Agentic RL 爆发与理论深化

Agentic RL 将 RLVR 范式从单一推理任务扩展到多步 tool-use Agent 场景:


方法	核心贡献	论文
Agent-R1	端到端 RL 训练 Agent	2511.14460
Tool-R1	样本高效的 Agent 工具使用 RL	2509.12867
SCRIBE	结构化中层监督，解决多步 Agent 的 credit assignment	2601.03555
SLEA-RL	步骤级经验增强的 Agent RL 训练	2603.18079

方法	核心贡献	论文
ASTRA	自动化 Agent 轨迹合成和 RL arena 构建	2601.21558

理论深化方面：

工作	核心论点	论文
Conditional Equivalence of DPO and RLHF	DPO 与 RLHF 在偏好数据覆盖足够好时等价，给出严格条件和失败模式	2605.20834
Post-Training is About States	SFT/RL/Distillation 本质是状态分布优化，而非 token 分布	2605.22731
Non-decoupling SFT and RL	SFT 与 RL 在训练动态中深度纠缠，不可割裂看待	2601.07389
SFT vs RL (Jiang et al.)	系统对比 SFT 与 RL 效果差异及适用场景	2603.13985

2.5 演进路径总结



└─ GRPO 变体 (31 篇)	[推理训练主流]
└─ Agentic RL 爆发	[Agent 训练]
└─ 理论深化 (DPO↔RLHF 等价性等)	[统一框架]
2026 — 理论统一 + 应用扩展 + 评估反思	[持续中]

3. 核心方法体系

3.1 训练范式分类

当前 LLM 后训练存在四大训练范式：

范式	核心思想	代表论文	优势	局限
SFT	在高质量指令-回答对上做交叉熵训练	Arena Learning 2407.10627	稳定、高效、无需 RM	缺乏偏好信号；分布外泛化差
Online RL (PPO-RLHF)	PPO + RM 在线优化，KL 约束	InstructGPT 2203.02155 ; Llama 2 2307.09288	理论上限高；在线探索	需 RM；训练不稳定；reward hacking
Offline DPO	直接在偏好对上优化隐式 reward	DPO 2305.18290 ; KTO 2402.01306	简单；无需 RM	离线数据分布受限
Group-wise (GRPO)	组内相对 advantage 代替 value function	DeepSeek-R1 2501.12948	无需 value function；适合可验证域	非可验证域受限

范式选择决策：

有 pairwise 偏好标注？
└─ 是 → 有持续标注预算？
└─ 是 → Online RLHF (PPO) 或 Iterative DPO
└─ 否 → 数据量大且覆盖好？
└─ 是 → offline DPO
└─ 否 → KTO (仅需单侧反馈)
└─ 否 → 有可验证 ground-truth 信号？
└─ 是 → GRPO / RLVR (数学、代码)
└─ 否 → 仅能做 SFT (或 RLAIIF 生成偏好数据)

SFT 的角色再定义 [确定]: SFT 已从"独立训练阶段"演化为"后训练 pipeline 的必要前序步骤"。近年关键洞察包括: (1) SFT 和 RL 的根本差别在状态分布而非 token 分布 [2605.22731]; (2) SFT 与 RL 在训练动态中深度纠缠, 不可解耦 [2601.07389]; (3) SFT 是 DPO 在 $\beta \rightarrow \infty$ 时的极限 [2507.00018]。

3.2 奖励建模

3.2.1 偏好模型分类

模型类别	数学形式	核心假设	代表论文	适用场景
Bradley-Terry (BT)	$P(y_w > y_l) = \sigma(r(y_w) - r(y_l))$	偏好传递性	DPO [2305.18290], 多数 RLHF	标准 pairwise 偏好
Plackett-Luce (PL)	$P(\text{perm}) \propto \prod \exp(r(y_i))$	扩展到 K 个排序	GOPO 2602.03876	多排序数据
前景理论	非对称价值函数	损失敏感度 $\neq$ 收益敏感度	KTO 2402.01306	仅单侧 $\checkmark/X$
Energy-Based	$p(y$	$x) \propto \exp(-E(x,y))$	能量函数 = 奖励	Energy-Based RM 2504.13134

3.2.2 显式 RM vs 隐式偏好函数

显式 RM (两阶段): 偏好数据 $\rightarrow$ 训练 RM $\rightarrow$ RM 评分优化策略
+ 可在线查询; 多任务复用
- RM 泛化差; reward hacking; 两阶段误差累积
隐式偏好函数 (端到端): 偏好数据 $\rightarrow$ 直接优化策略 $\rightarrow$ 无需独立 RM
+ 简单; 训练稳定
- 离线数据依赖; 无法在线探索

争议现状 [确定]: RM 并未因 DPO 出现而消失。2025-2026 的 RM 工作转向"更聪明的 RM"而非"要不要 RM"——如 Unsupervised PRM [2605.10158]、Causal Rewards [2501.09620]、Activation-based RM [2507.01368]、Directional Alignment [2605.25189]。

3.2.3 ORM vs PRM

维度	ORM (结果奖励)	PRM (过程奖励)
评分粒度	整个回答一个分数	每个推理步骤一个分数
适用场景	对话、摘要	数学推理、多步规划
训练数据	pairwise/pointwise 偏好	步骤级正确性标注
核心挑战	粗粒度，无法指导中间推理	标注成本极高；步骤粒度定义模糊
前沿方向	—	无监督 PRM [2605.10158]; 双向 PRM [2508.01682]; Activation-based RM [2507.01368]

PRM 数据构建三路线：

1. 人工标注（最权威）：GroundedPRM [2510.14942] — 树搜索 + 保真度感知
2. 自动化路线（利用 ground truth 反推）：不确定性方法 [2508.01773]
3. 无监督（无需步骤标注）：Free Process Rewards [2412.01981]; Unsupervised PRMs [2605.10158]

3.2.4 Reward Hacking 问题谱系

Reward Hacking 是 RLHF 的核心挑战，表现为策略优化了 reward model 的"代理指标"而非真实目标。

类型	表现	缓解方法	代表论文
长度偏置	越长回答 reward 越高	Length-Controlled Eval [2404.04475]	Lu 2406.10957
风格过拟合	学习 RM 偏好的表面风格	RM 对抗训练; Ensemble	Feuer 2409.15268
多目标 Reward Hacking	多目标间投机	MO-GRPO [2509.22047]	Ichihara 2509.22047
生产环境 Hacking	真实部署中利用系统漏洞	因果 reward; 方向对齐	MacDiarmid 2511.18397

类型	表现	缓解方法	代表论文
迭代自 Refinement Hacking	自我迭代时偏离目标	elastic reset [2312.07551]	Pan 2407.04549
Agent 情境 Hacking	Agent 在 tool-use 中利用漏洞	结构化中间监督 [2601.03555]	Roth 2605.20744

关键缓解方法：

- **RM Ensemble** [2312.09244] — 缓解但不能消除
- 对抗 **RM** 训练 [2504.06141]
- 因果 **Reward** [2501.09620] — 用因果推断区分行为与奖励的真实因果关系
- 方向对齐 [2605.25189] — 约束策略梯度方向与参考模型一致
- 进化 **RM** [2504.20157] — RL 过程中同时进化 RM

核心结论[确定]: *Reward Hacking* 是 *Goodhart's Law* 的实例——“当一个度量成为目标时，它就不再是好的度量”。*RM Ensemble* 只能缓解不能消除，*Causal Rewards* 和 *Directional Alignment* 是最有前景的新方向。

3.3 DPO 方法族详解

3.3.1 核心 DPO (Rafailov et al., 2023)

理论推导链条：

BT 偏好模型 → RLHF 最优策略闭式解 → 隐式 reward 反推 → DPO 损失函数

$$P(y_w > y_l) = \sigma(r(y_w) - r(y_l))$$
$$\pi^*(y|x) \propto \pi_{\text{ref}}(y|x) \cdot \exp(r(x,y)/\beta)$$
$$r(x,y) = \beta \cdot \log(\pi(y|x) / \pi_{\text{ref}}(y|x))$$

优势：无需 RM，端到端训练。

局限：完全离线，无法探索新分布；对 π_{ref} 质量敏感；over-optimization 依然存在 [2406.02900]；Likelihood Displacement [2410.08847] — chosen probability 上升但 rejected probability 未充分降低。

3.3.2 关键变体详解

KTO [2402.01306]: 基于 Kahneman-Tversky 前景理论，仅需 ✓/X 标签。核心创新：人类对损失的敏感度大于收益，偏好优化也应体现这种不对称性。无需 pairwise 数据使其更贴合实际标注场景。

ORPO [2403.07691]: 合并 SFT + 偏好优化为单一训练阶段。odd 比公式： $\text{odds}_{\theta}(y|x) = \frac{\pi_{\theta}(y|x)}{(1-\pi_{\theta}(y|x))}$ 。无需参考模型，内存/计算减半。

SimPO [2405.14734]: 长度归一化的平均 log probability 作为隐式 reward： $r_{\text{SimPO}} = (\beta/|y|) \cdot \log \pi_{\theta}(y|x)$ 。引入 target reward margin γ 确保 chosen 显著优于 rejected。在 AlpacaEval 上匹配或超越 DPO。

Online DPO [2406.05534]: Fast-Slow Chasing 机制——fast model 更新快但噪声大，slow model 稳定但滞后。用 slow model 的隐式 reward 对 fast model 采样做偏好标注，实现在线采样与离线优化的解耦。

Conditional Equivalence [2605.20834] (2026): DPO 仅在偏好数据覆盖足够好时等价于 RLHF；揭示 DPO 的隐式假设和失败模式。这一工作为"DPO vs RLHF"的长期争议提供了理论终局。

3.4 GRPO 与推理增强

3.4.1 为什么 GRPO 重要

GRPO 的三个核心优势：

1. 无需 **Value Function**: 用组内相对归一化替代 PPO 的价值网络，简化架构
2. 天然适合可验证域: 数学答案、代码执行等可自动获得 ground-truth reward
3. 发现而非灌输: DeepSeek-R1-Zero 证明了模型可以在纯 RL 中"自己学会"推理策略

3.4.2 GRPO 的理论理解

根据 Demystifying GRPO [2603.01162]:

- GRPO 的策略梯度本质上是 **U-Statistic** — 一种不依赖于参数模型的非参数统计量
- 方差以 $O(1/G)$ 递减，G 越大方差越小

- 但 G 越大采样成本越高，超参数选择缺乏理论指导

3.4.3 GRPO 的主要挑战

1. 非可验证域困境: 31 篇 GRPO 论文几乎全在 math/code 场景，无法迁移至创意写作、开放域对话
2. **Reward** 方差敏感: 高方差 reward landscape 中 bias 严重 (BiasGRPO [2606.04807] 尝试缓解)
3. 最优组大小 G 的理论缺失: 实用中 $G=4\sim 16$ ，但理论最优值未知
4. 与 **PPO** 的关系: 部分论文认为 GRPO 是 off-policy 的 REINFORCE 变体 [2509.24203]，争议存在

3.5 Agentic RL

定义: 将 RL/偏好优化应用于多步 tool-use / Agent 场景。

核心挑战:

1. 奖励稀疏性: 多步任务只在最终有成功/失败信号
2. 信用分配: 哪个中间步骤导致了最终失败?
3. 环境交互成本: 真实 API 调用成本高
4. 训练-部署环境差异: Agent 在训练中接触的 API/工具与部署时不同

当前方法路线:

- **RLVR** 路线 (Agent-R1 [2511.14460]): GRPO 范式迁移至 Agent 训练
 - 过程监督路线 (SCRIBE [2601.03555]): 结构化中层监督
 - **Multi-Turn PO** 路线 (SLEA-RL [2603.18079]): DPO 扩展到多轮交互
 - 自博弈路线 (SPPO [2405.00675]): 模型自身生成数据进行迭代优化
-

4. 实验室与团队格局

4.1 工业界核心实验室

实验室	核心贡献	关键人物	方法路线
OpenAI	InstructGPT; PPO; RLHF 范式创立	Schulman, Ouyang, Christiano	PPO-RLHF (保守实践)
Anthropic	Constitutional AI; Helpful & Harmless; RLAIIF	Bai, Askell, Amodei	AI 反馈 + 安全对齐
Google DeepMind	RLAIIF 系统验证; Reward Hacking 分析	Lee, Eisenstein	评估 + 奖励建模
Meta AI	Llama 2 RLHF 工业化; Toolformer	Touvron	开源 RLHF 工程
DeepSeek	GRPO 算法; DeepSeek-R1; RLVR 范式	DeepSeek-AI (集体)	组相对优化 + 推理
Salesforce	RLHF 理论分析; 迭代偏好学习	Wei Xiong	理论桥梁
Contextual AI	KTO (前景理论)	Ethayarajh, Kiela	行为经济学视角

4.2 学术界核心团队

团队	核心贡献	关键人物
Stanford	DPO 发明; 偏好优化方法族奠基	Rafailov, Finn, Manning
Princeton	SimPO (无参考模型)	Meng, Chen
KAIST	ORPO (SFT+偏好联合)	Hong, Thorne
UIUC	RLHF 理论分析; 在线对齐	Wei Xiong
Tsinghua	UltraFeedback 数据; AlignBench 评估; ToolLLM Agent	Cui, Liu, Qin, Ji
LMSYS	Chatbot Arena; MT-Bench 评估标准	Zheng, Chiang, Li

4.3 人才流动

2024 年发生了显著的人才流动：

- **John Schulman** (OpenAI → Anthropic) — PPO 发明者
- **Jan Leike** (OpenAI → Anthropic) — 前 Alignment 负责人
- **Ilya Sutskever** (OpenAI → SSI) — 创立 Safe Superintelligence Inc.
- **Paul Christiano** (OpenAI → ARC) — RLHF 概念先驱，创立 Alignment Research Center

[推断] 这些流动反映了 AI 安全领域的加速分化：*OpenAI* 逐渐商业化，*Anthropic* 更加聚焦安全对齐。

4.4 开源社区基础设施

项目	贡献
HuggingFace TRL	最常用的 RLHF 训练框架 (PPO, DPO)
OpenRLHF	大规模 RLHF 框架 (Ray + vLLM)
DeepSpeed-Chat	三步 RLHF 训练管线
LLaMA-Factory	中文社区最流行的微调工具
Chatbot Arena (LMSYS)	独立评估裁判平台

5. 评估体系

5.1 评估框架总览

平台	类型	核心指标	代表论文
AlpacaEval 2.0	LLM-as-judge	Length-Controlled Win Rate	2404.04475
MT-Bench	LLM-as-judge	多轮对话评分 (1-10)	2306.05685
Chatbot Arena	人类投票	Elo Score	2306.05685 ; 2403.04132
Arena-Hard	LLM-as-judge	Win Rate (难样本)	2406.11939
JudgeBench	Meta-评估	Judge 准确率	2410.12784
AlignBench	LLM-as-judge	中文多维评分	2311.18743

平台	类型	核心指标	代表论文
PRMBench	PRM 评估	PRM 准确率	2501.03124

5.2 LLM-as-Judge 的可靠性危机

五大批评[确定]:

- 1. 长度偏置 [2404.04475] – LLM judge 系统性偏好更长回答
- 2. 风格优于实质 [2409.15268] – 偏好格式/礼貌超过内容质量
- 3. **Null Model** 攻击 [2410.07137] – 始终输出固定文本的模型获得高 win rate
- 4. 非传递性 [2502.14074] – $A > B, B > C$ 但 $C > A$, 动摇 Elo 评分数学基础
- 5. 排行榜幻觉 [2504.20879] – 排行榜已成为优化目标而非科学测量

现状[争议]: 社区共识是"多指标、多 *benchmark* 交叉验证", 单一排行榜排名不再被严肃研究接受。但评估生态的根本性修复尚未完成。

6. 未解决问题与挑战

6.1 方法层面

问题	严重程度	说明
Reward Hacking 无通用解决方案	P0	所有 RL/偏好优化方法被 RM 质量锁定上限
非可验证域 RLVR 缺失	P0	GRPO/R1 范式锁死在 math/code, 无法迁移至创意、对话
DPO 与 RLHF 真实性能差距	P1	Conditional Equivalence [2605.20834] 揭示等价需要严格条件
多步 Agent Credit Assignment	P1	SCRIBE [2601.03555]、SLEA-RL [2603.18079] 提供了部分方案但远未解决
GRPO 理论完备性不足	P2	最优 G、收敛性、与 PPO 的理论关系模糊
SFT 与 RL 的解耦性	P2	Non-decoupling [2601.07389] 论证二者不可割裂

6.2 数据层面

问题	说明
Human vs AI Feedback 差距	RLAIF 在某些场景接近 human feedback，但偏置传播风险
合成数据质量退化	多轮自举可能导致"数据近亲繁殖"
偏好数据普适性	偏好高度依赖标注者群体，跨文化对齐不足
PRM 数据瓶颈	无监督 PRM [2605.10158] 兴起但仍不如监督

6.3 评估层面

问题	说明
LLM-judge 偏置无法根除	LC 修正了长度但风格偏置仍在
推理评估缺少标准	开放领域推理质量无 ground-truth
安全对齐评估困境	安全性难以量化为单一指标
对齐税	RLHF 可能降低某些能力，缺乏系统和风险的量化

6.4 理论层面

问题	说明
Reward Hacking 理论边界	是否存在根本上可避免 reward hacking 的框架？
KL 约束理论基础	最优 KL 约束形式（reverse vs forward vs f-divergence）缺乏理论
对齐长期稳定性	部署后 alignment drift 的监测几乎空白

7. 未来方向预判

7.1 短期方向 (1-2 年, 已有初步探索)

1. **RLVR** → 通用对齐的统一框架 🔥 🔥 🔥 🔥 🔥
 - 将 GRPO/RLVR 从可验证域扩展到非可验证域
 - 早期信号: References Improve LLM Alignment [2602.16802], Flip Side of RLHF [2605.30888]
2. 在线+离线混合偏好优化 🔥 🔥 🔥 🔥
 - 结合离线 DPO 的高效性和在线 RL 的探索能力
 - 早期信号: Online DPO [2406.05534], Self-Exploring LMs [2405.19332]
3. **Agent RL** 方法论固化 🔥 🔥 🔥 🔥 🔥
 - 将 GRPO/PRM 系统化迁移至 Agent 训练
 - 早期信号: Agent-R1 [2511.14460], Tool-R1 [2509.12867]
4. 评估基础设施的修复 🔥 🔥 🔥 🔥
 - 解决 LLM-as-Judge 的非传递性、偏差和可欺骗性问题

7.2 中期方向 (2-4 年)

5. 自演化对齐 — 部署后持续通过自身经验改进对齐
6. 多智能体对齐 — 多 LLM Agent 系统的对齐问题
7. **Post-Training** 统一理论 — 将 SFT/RLHF/DPO/GRPO 统一到同一框架

7.3 长期方向 (4-6 年)

8. 超越偏好的对齐信号 — Causal Rewards [2501.09620]、信息论对齐
9. 对齐与能力获取的统一 — 端到端的能力获取+对齐过程

7.4 四个突破点

1. **GRPO** 的"通用化" — 从可验证域扩展到通用对齐, 将是 DPO 之后的又一次范式转折 (预判: 2026 下半年至 2027)
2. **LLM-as-Judge** 的"可信化" — 解决非传递性, 设计不可欺骗的评估 (预判: 2027-2028)

3. **Post-Training** 统一理论 — 指导 pipeline 设计，结束"试错法"（预判: 2027-2028）

4. 单 **Agent** → 多 **Agent** 对齐 — 多 LLM 系统的对齐成为刚需（预判: 2027-2029）

8. 结论

LLM 强化学习后训练正经历自 **DPO** 以来的第二次方法革命。2025-2026 的 **GRPO**/**RLVR** 范式不仅重新定义了推理能力训练，更通过 **Agentic RL** 将 **RL** 的角色从"对齐"扩展至"能力获取"。

五大核心结论：

1. **GRPO** 是当前最重要的方法创新 — 31 篇论文全在 2025-2026，增速远超其他方向
2. **DPO** 方法族趋于成熟 — 边际创新递减，核心有持久价值的变体不超过 10 个
3. **Reward Hacking** 是未解决的一级风险 — 所有方法都面临，无通用解决方案
4. 评估体系需要根本性修复 — 非传递性 [2502.14074] 和排行榜幻觉 [2504.20879] 已积累足够批评
5. **Agentic RL** 是下一个主战场 — 谁能解决 **credit assignment** 和训练效率，谁就掌握 **Agent** 产品化的关键能力

对实践者的建议：首选 **GRPO + Agentic RL**（主赛道），次选非可验证域 **RLVR**（最大空白，高回报），储备 **PRM** 能力（关键增强组件），建立多维度评估体系（不要依赖单一排行榜）。

参考文献

本报告涉及的 280 篇论文完整列表见 [research/paper_inventory.md](#)。以下为核心参考文献：

里程碑论文

- [1707.06347] Schulman et al. Proximal Policy Optimization Algorithms. 2017. <https://arxiv.org/abs/1707.06347>
- [1706.03741] Christiano et al. Deep Reinforcement Learning from Human

- Preferences. 2017. <https://arxiv.org/abs/1706.03741>
- [2203.02155] Ouyang et al. Training Language Models to Follow Instructions with Human Feedback (InstructGPT). 2022. <https://arxiv.org/abs/2203.02155>
 - [2204.05862] Bai et al. Training a Helpful and Harmless Assistant with Reinforcement Learning from Human Feedback. 2022. <https://arxiv.org/abs/2204.05862>
 - [2212.08073] Bai et al. Constitutional AI: Harmlessness from AI Feedback. 2022. <https://arxiv.org/abs/2212.08073>
 - [2305.18290] Rafailov et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. 2023. <https://arxiv.org/abs/2305.18290>
 - [2307.09288] Touvron et al. Llama 2: Open Foundation and Fine-Tuned Chat Models. 2023. <https://arxiv.org/abs/2307.09288>
 - [2501.12948] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. 2025. <https://arxiv.org/abs/2501.12948>

核心方法论文

- [2310.01377] Cui et al. UltraFeedback: Boosting Language Models with High-Quality Feedback. 2023. <https://arxiv.org/abs/2310.01377>
- [2309.00267] Lee et al. RLAIFF: Scaling Reinforcement Learning from Human Feedback with AI Feedback. 2023. <https://arxiv.org/abs/2309.00267>
- [2306.05685] Zheng et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. 2023. <https://arxiv.org/abs/2306.05685>
- [2307.16789] Qin et al. ToolLLM: Facilitating Large Language Models to Master 16000+ Real-world APIs. 2023. <https://arxiv.org/abs/2307.16789>
- [2402.01306] Ethayarajh et al. KTO: Model Alignment as Prospect Theoretic Optimization. 2024. <https://arxiv.org/abs/2402.01306>
- [2403.07691] Hong et al. ORPO: Monolithic Preference Optimization without Reference Model. 2024. <https://arxiv.org/abs/2403.07691>
- [2405.14734] Meng et al. SimPO: Simple Preference Optimization with a Reference-Free Reward. 2024. <https://arxiv.org/abs/2405.14734>
- [2406.05534] Qi et al. Online DPO: Fast-Slow Chasing for Alignment. 2024. <https://arxiv.org/abs/2406.05534>
- [2406.11817] Liu et al. Iterative Length-Regularized DPO. 2024. <https://arxiv.org/abs/2406.11817>
- [2405.00675] Wu et al. Self-Play Preference Optimization for Language Model

- Alignment. 2024. <https://arxiv.org/abs/2405.00675>
- [2406.02900] Rafailov et al. Scaling Laws for Reward Model Overoptimization. 2024. <https://arxiv.org/abs/2406.02900>
 - [2404.19733] Pang et al. Iterative Reasoning Preference Optimization. 2024. <https://arxiv.org/abs/2404.19733>
 - [2406.14868] Shi et al. Direct Multi-Turn Preference Optimization for Agents. 2024. <https://arxiv.org/abs/2406.14868>
 - [2603.01162] Zhou et al. Demystifying GRPO: Its Policy Gradient is a U-Statistic. 2026. <https://arxiv.org/abs/2603.01162>
 - [2605.20834] Yang et al. Conditional Equivalence of DPO and RLHF. 2026. <https://arxiv.org/abs/2605.20834>
 - [2605.22731] Nie et al. Post-Training is About States, Not Tokens. 2026. <https://arxiv.org/abs/2605.22731>
 - [2601.07389] Niu et al. On the Non-decoupling of Supervised Fine-tuning and Reinforcement Learning. 2026. <https://arxiv.org/abs/2601.07389>
 - [2603.13985] Jiang et al. Supervised Fine-Tuning versus Reinforcement Learning. 2026. <https://arxiv.org/abs/2603.13985>

GRPO 变体与 Agent RL

- [2511.14460] Cheng et al. Agent-R1: End-to-End RL for Tool-Using Agent. 2025. <https://arxiv.org/abs/2511.14460>
- [2509.12867] Zhang et al. Tool-R1: Sample-Efficient Tool-Using RL for LLM Agents. 2025. <https://arxiv.org/abs/2509.12867>
- [2509.22047] Ichihara et al. MO-GRPO: Mitigating Reward Hacking on Multi-Objective Problems. 2025. <https://arxiv.org/abs/2509.22047>
- [2604.20659] Wang et al. GRPO-VPS: Verifiable Process Supervision for GRPO. 2026. <https://arxiv.org/abs/2604.20659>
- [2601.03555] Jiang et al. SCRIBE: Structured Mid-Level Supervision for Tool-Using LMs. 2026. <https://arxiv.org/abs/2601.03555>
- [2603.18079] Wang et al. SLEA-RL: Step-Level Experience Augmented RL for Agents. 2026. <https://arxiv.org/abs/2603.18079>
- [2601.21558] Tian et al. ASTRA: Automated Synthesis of Agentic Trajectories and Reinforcement Arenas. 2026. <https://arxiv.org/abs/2601.21558>

Reward Hacking 与安全

- [2312.09244] Eisenstein et al. Helping or Herding? Reward Model Ensembles Mitigate but do not Eliminate Reward Hacking. 2023. <https://arxiv.org/abs/2312.09244>
- [2511.18397] MacDiarmid et al. Natural Emergent Misalignment from Reward Hacking in Production RL. 2025. <https://arxiv.org/abs/2511.18397>
- [2501.09620] Wang et al. Causal Rewards for Language Model Alignment. 2025. <https://arxiv.org/abs/2501.09620>
- [2604.13602] Wang et al. Reward Hacking in the Era of Large Models. 2026. <https://arxiv.org/abs/2604.13602>
- [2605.25189] Deng et al. Directional Alignment Mitigates Reward Hacking. 2026. <https://arxiv.org/abs/2605.25189>
- [2605.30888] Wang et al. The Flip Side of RLHF: On-Policy Feedback for RM Self-Supervised Improvement. 2026. <https://arxiv.org/abs/2605.30888>

评估危机

- [2404.04475] Dubois et al. Length-Controlled AlpacaEval. 2024. <https://arxiv.org/abs/2404.04475>
- [2409.15268] Feuer et al. Style over Substance: Failure Modes of LLM Judges. 2024. <https://arxiv.org/abs/2409.15268>
- [2410.07137] Zheng et al. Judging the Judges: Evaluating Alignment Benchmarks with Null Models. 2024. <https://arxiv.org/abs/2410.07137>
- [2502.14074] Xu et al. Investigating Non-Transitivity in LLM-as-a-Judge. 2025. <https://arxiv.org/abs/2502.14074>
- [2504.20879] Singh et al. The Leaderboard Illusion. 2025. <https://arxiv.org/abs/2504.20879>

PRM 与过程监督

- [2501.07301] Zhang et al. The Lessons of Developing Process Reward Models. 2025. <https://arxiv.org/abs/2501.07301>
- [2412.01981] Yuan et al. Free Process Rewards without Process Labels. 2024. <https://arxiv.org/abs/2412.01981>
- [2605.10158] Gadetsky et al. Unsupervised Process Reward Models. 2026. <https://arxiv.org/abs/2605.10158>

- [2507.01368] Chai et al. Activation Reward Models for Few-Shot Model Alignment. 2025. <https://arxiv.org/abs/2507.01368>

综述与统一

- [2310.19852] Ji et al. AI Alignment: A Comprehensive Survey. 2023. <https://arxiv.org/abs/2310.19852>
- [2509.04419] Lv et al. Towards a Unified View of LLM Post-Training. 2025. <https://arxiv.org/abs/2509.04419>
- [2507.00018] Wang et al. Implicit Reward as the Bridge: A Unified View of SFT and DPO. 2025. <https://arxiv.org/abs/2507.00018>

本报告基于 *research/* 目录下 280 篇论文的系统文献调研生成。所有引用均可追溯到 *paper_inventory.md* 中的具体条目。标注 [推断] 的判断为基于数据和趋势的合理推测，非确定性结论。标注 [争议] 的结论存在学术界明显分歧。